# Complexité I/O

Auguste Olivry, Guillaume looss, Fabrice Rastello

Équipe Inria CORSE, Grenoble

17 Mars 2022

# Optimisation de programme

 Comment modifier un programme pour qu'il s'exécute le plus rapidement possible sur une machine?

# Optimisation de programme

• Comment modifier un programme pour qu'il s'exécute le plus rapidement possible sur une machine?

- Aspects à prendre en compte:
  - Utiliser au maximum les unités de calcul
  - Acheminer les données demandées par ces unités de calcul

# Optimisation de programme


 Comment modifier un programme pour qu'il s'exécute le plus rapidement possible sur une machine?

- Aspects à prendre en compte:
  - Utiliser au maximum les unités de calcul
  - Acheminer les données demandées par ces unités de calcul

- Limites venant de l'architecture:
  - Puissance de calcul (nombre d'unités de calcul, fréquence, . . . )
  - Bande-passante entre les mémoires (RAM, caches, registres)


## Roofline model

• Roofline model: modélise l'équilibre de la machine



## Roofline model

Roofline model: modélise l'équilibre de la machine




### Programme memory/compute-bound

- Memory-bound: les transferts mémoires limitent la perf
- Compute-bound: les unités de calcul limitent la perf

## Roofline model

Roofline model: modélise l'équilibre de la machine



### Programme memory/compute-bound

- Memory-bound: les transferts mémoires limitent la perf
- Compute-bound: les unités de calcul limitent la perf
- Transformation: peut améliorer la réutilisation mémoire
  - ⇒ Décalage vers la droite




# Optimiser l'I/O

- Évolution de l'équilibre machine:
  - Intel 80286: 2 MIPS, 13 MB/s transfert RAM->CPU
  - Intel core i7: 50k MIPS, 16k MB/s transfert RAM->CPU

# Optimiser I'I/O

- Évolution de l'équilibre machine:
  - Intel 80286: 2 MIPS, 13 MB/s transfert RAM->CPU
  - Intel core i7: 50k MIPS, 16k MB/s transfert RAM->CPU
- Évolution ratio énergie calcul/transfert données:



⇒ I/O de plus en plus critique/difficile à optimiser.




## Limite algorithmique à l'intensité opérationnelle

- Transfo améliorant l'efficacité d'utilisation des données:
  - ⇒ Décale vers la droite... mais jusqu'à quel point est-ce possible?


# Limite algorithmique à l'intensité opérationnelle

- Transfo améliorant l'efficacité d'utilisation des données:
  - ⇒ Décale vers la droite... mais jusqu'à quel point est-ce possible?



# Limite algorithmique à l'intensité opérationnelle


- Transfo améliorant l'efficacité d'utilisation des données:
  - ⇒ Décale vers la droite... mais jusqu'à quel point est-ce possible?



Quel est le nombre maximum de calcul par I/O ?
 (OU) Quel est le nombre minimal d'I/O devant être fait?


# Complexité I/O - Définition

• Modèle mémoire à 2 niveaux:



# Complexité I/O - Définition

• Modèle mémoire à 2 niveaux:



### Coût I/O


• Nombre de transferts mémoire, pour un ordonnancement donné

 Introduction
 Modélisation
 Borne inf
 Borne sup
 Résultats

 0000€0
 00000
 000000000
 00000000
 00000000

# Complexité I/O - Définition

Modèle mémoire à 2 niveaux:



### Coût I/O

• Nombre de transferts mémoire, pour un ordonnancement donné

### Complexité I/O

- Nombre de transferts mémoire min, pour tout ordonnancement
- ⇒ Comment calculer la complexité I/O d'un programme?



## Plan du reste de l'exposé

- Introduction
  - Motivation générale
  - Complexité I/O
- Red-white pebble game
- Borne inférieure
- Borne supérieure
- 6 Résultats

- Comment modéliser le nombre de transferts vers la mémoire rapide?
- Red/White Pebble game (variation de [Hong and Kung 1981])

- Comment modéliser le nombre de transferts vers la mémoire rapide?
- Red/White Pebble game (variation de [Hong and Kung 1981])

### Principes généraux

Introduction

- Computational Directed Acyclic Graph (CDAG): graphe des calculs d'un programme
  - Nœud: Entrées, sorties et opérations du programme
  - Arête: Dépendance de donnée entre calculs

- Comment modéliser le nombre de transferts vers la mémoire rapide?
- Red/White Pebble game (variation de [Hong and Kung 1981])

### Principes généraux

Introduction

- Computational Directed Acyclic Graph (CDAG): graphe des calculs d'un programme
  - Nœud: Entrées, sorties et opérations du programme
  - Arête: Dépendance de donnée entre calculs
- Jetons se placent sur les nœuds:
  - Jeton Rouge = Donnée actuellement dans la mémoire rapide Seulement *S* jetons rouges!
  - Jeton Blanc = Calcul effectué, donnée dans la mémoire lente

- Comment modéliser le nombre de transferts vers la mémoire rapide?
- Red/White Pebble game (variation de [Hong and Kung 1981])


### Principes généraux

- Computational Directed Acyclic Graph (CDAG): graphe des calculs d'un programme
  - Nœud: Entrées, sorties et opérations du programme
  - Arête: Dépendance de donnée entre calculs
- Jetons se placent sur les nœuds:
  - Jeton Rouge = Donnée actuellement dans la mémoire rapide Seulement *S* jetons rouges!
  - Jeton Blanc = Calcul effectué, donnée dans la mémoire lente
- Situation initiale: jetons blancs sur les nœuds d'entrée
- But du jeu: couvrir tous les nœuds avec des jetons blancs

# Règles du jeu

### Règle 1 - Load

On peut mettre un jeton rouge sur un nœud avec un jeton blanc.




## Règles du jeu

### Règle 1 - Load

On peut mettre un jeton rouge sur un nœud avec un jeton blanc.

### Règle 2 - Calcul

Si un nœud n'a pas de jeton blanc et que tous ses prédécesseurs ont un jeton rouge, on peut y mettre un rouge et un blanc.



## Règles du jeu

### Règle 1 - Load


On peut mettre un jeton rouge sur un nœud avec un jeton blanc.

### Règle 2 - Calcul

Si un nœud n'a pas de jeton blanc et que tous ses prédécesseurs ont un jeton rouge, on peut y mettre un rouge et un blanc.

### Règle 3 - Oubli

On peut retirer un jeton rouge d'un nœud.



Modélisation Introduction Borne inf Résultats

## Règles du jeu

### Règle 1 - Load


On peut mettre un jeton rouge sur un nœud avec un jeton blanc.

### Règle 2 - Calcul

Si un nœud n'a pas de jeton blanc et que tous ses prédécesseurs ont un jeton rouge, on peut y mettre un rouge et un blanc.


#### Règle 3 - Oubli


On peut retirer un jeton rouge d'un nœud.





• Pas de recalculs. Nombre Load = nombre de Règle 1.

















































































Nombre total de loads: 14.



Nombre total de loads: 14. (Il y a une solution à 9)



# Problèmes (Challenges)

- Problèmes:
  - Besoin d'un minimum sur toutes les parties

# Problèmes (Challenges)

#### Problèmes:

- Besoin d'un minimum sur toutes les parties
- Taille du CDAG fréquemment paramétrique:

Nombre de Load dépend de ces paramètres.

# Problèmes (Challenges)

#### Problèmes:

- Besoin d'un minimum sur toutes les parties
- Taille du CDAG fréquemment paramétrique:

```
for (i=1; i<N; i++)
t += A[i-1] + A[i];
```

Nombre de Load dépend de ces paramètres.

- Infaisable sur des graphes quelconques
- ⇒ Se restreint à des graphes de programmes réguliers.

### Programme polyédrique

### Classe de programme: programme polyédrique

Conditions de boucle + fonctions d'accès affines

#### Example (Multiplication de matrice)

```
for (i=0; i<I; i++)
  for (j=0; j<J; i++) {
    for (k=0; k<K; i++)
S:    C[i,j] += A[i,k] * B[k,j];
}</pre>
```

Domaine d'itération:  $D_S = \{i, j, k \mid 0 \le i < I, 0 \le j < J, 0 \le k < K\}$ Fonction d'accès:  $f_C = (i, j, k - > i, j)$ 

⇒ Représentation mathématique précise et compacte du CDAG. (Parenthèse opportuniste sur la compilation polyédrique)

# Plan de l'exposé (en cours)

- Introduction
  - Motivation générale
  - Complexité I/O
- Red-white pebble game
- Borne inférieure
- Borne supérieure
- 6 Résultats

# Borne inférieure d'une complexité I/O

- Considérons un programme polyédrique:
   Borne symbolique inférieure de sa complexité I/O ?
- Plusieurs méthodes de preuve: wavefront, 2S-partitions, ...
  - Efficacité dépend de la structure du graphe
- lci: présentation de la méthode des 2S-partitions.

### K-partition - Définition

#### En posant:

- CDAG = (V, E).
- $I \subseteq V$ : Nœuds d'entrée de V.
- $V_i$ : sous-ensemble de V.

### $InSet(V_i)$

Ensemble des nœuds hors de  $V_i$  et prédécesseurs de nœuds de  $V_i$ .

#### K-ensemble

Ensemble V de nœuds tel que  $|InSet(V)| \leq K$ 

# K-partition

### K-partition

Partition  $(V_i)_i$  de (V - I), telle que:

- tous les  $V_i$  sont des K-ensembles
- Pas de cycles entre  $V_i$

### K-partition

#### K-partition

Partition  $(V_i)_i$  de (V - I), telle que:

- tous les  $V_i$  sont des K-ensembles
- Pas de cycles entre  $V_i$

#### Utilité?

- Si K = S + T (avec S = taille de la mémoire rapide), au moins T loads dans le meilleur cas par ensemble.
- Possible de ramener tout jeu de jetons Rouge-Blanc à une décomposition en 2S-partition.

### Idée générale de la méthode des 25-partitions

### Lemma (Lien entre une 2S-partition et la complexité I/O)

Soit P le plus grand ensemble d'une 2S-partition, et Q la complexité I/O d'un programme. Alors:

$$Q \ge \left( \left\lceil \frac{|V|}{|P|} \right\rceil - 1 \right) \times S - |I|$$

### Idée générale de la méthode des 2*S*-partitions

### Lemma (Lien entre une 2S-partition et la complexité I/O)

Soit P le plus grand ensemble d'une 2S-partition, et Q la complexité I/O d'un programme. Alors:

$$Q \ge \left( \left\lceil \frac{|V|}{|P|} \right\rceil - 1 \right) \times S - |I|$$

Morceau restant: taille maximale d'un 2S-ensemble (càd de P) ?

## Théorème de Loomis-Whitney (1)

Taille maximale d'un K-ensemble?

#### Théorème de Loomis-Whitney


Soit  $E \subset \mathbb{R}^d$  et  $\phi_1, \ldots, \phi_d$  les projections canoniques.

Alors:

$$|E| \le \prod_{i=1}^{d} |\phi_i(E)|^{1/(d-1)}$$


## Théorème de Loomis-Whitney (2)

#### Example (d=3):



$$|E| \le |\phi_1(E)|^{1/2} \times |\phi_2(E)|^{1/2} \times |\phi_3(E)|^{1/2}$$

### Théorème de Loomis-Whitney (2)



• **Intuition:** S'arranger pour que les  $\phi_i(E)$  s'injectent dans une partie de InSet(E) (qui est de taille bornée)

```
for (i=0; i<I; i++)
  for (j=0; j<J; i++) {
    C[i,j] = 0;
    for (k=0; k<K; i++)
S:    C[i,j] += A[i,k] * B[k,j];
}</pre>
```

• **CDAG:** cube de 2*IJK* nœuds, avec projections selon les axes *i* et *j* et chaîne de dépendance selon *k* (axe de réduction)

```
for (i=0; i<I; i++)
  for (j=0; j<J; i++) {
    C[i,j] = 0;
    for (k=0; k<K; i++)
S:    C[i,j] += A[i,k] * B[k,j];
}</pre>
```

- **CDAG:** cube de 2*IJK* nœuds, avec projections selon les axes *i* et *j* et chaîne de dépendance selon *k* (axe de réduction)
- Soit P un K-ensemble de cet espace:

$$|P| \le |\phi_1(P)|^{1/2} \times |\phi_2(P)|^{1/2} \times |\phi_3(P)|^{1/2}$$

avec les  $\phi_i$  projections canoniques.

```
for (i=0; i<I; i++)
  for (j=0; j<J; i++) {
    C[i,j] = 0;
    for (k=0; k<K; i++)
S:    C[i,j] += A[i,k] * B[k,j];
}</pre>
```

- **CDAG:** cube de 2*IJK* nœuds, avec projections selon les axes *i* et *j* et chaîne de dépendance selon *k* (axe de réduction)
- Soit *P* un *K*-ensemble de cet espace:

$$|P| \le |\phi_1(P)|^{1/2} \times |\phi_2(P)|^{1/2} \times |\phi_3(P)|^{1/2}$$

avec les  $\phi_i$  projections canoniques.

• Or,  $|\phi_i(P)| \leq |InSet(P)| \leq K$ .

```
for (i=0; i<I; i++)
  for (j=0; j<J; i++) {
    C[i,j] = 0;
    for (k=0; k<K; i++)
S:    C[i,j] += A[i,k] * B[k,j];
}</pre>
```

- CDAG: cube de 2IJK nœuds, avec projections selon les axes i et j et chaîne de dépendance selon k (axe de réduction)
- Soit *P* un *K*-ensemble de cet espace:

$$|P| \le |\phi_1(P)|^{1/2} \times |\phi_2(P)|^{1/2} \times |\phi_3(P)|^{1/2}$$

avec les  $\phi_i$  projections canoniques.

- Or,  $|\phi_i(P)| \leq |InSet(P)| \leq K$ .
- Donc,  $|P| \le K^{3/2}$ .

• Considérons une (2S)-partition:

$$Q \ge \left( \left\lceil \frac{|V|}{|P|} \right\rceil - 1 \right) \times S - |I|$$

• Considérons une (2S)-partition:

$$Q \ge \left( \left\lceil \frac{|V|}{|P|} \right\rceil - 1 \right) \times S - |I|$$

• On a trouvé que  $|P| \le (2S)^{3/2}$  et |V| = 2IJK.

$$Q \ge \left( \left\lceil \frac{2IJK}{(2S)^{3/2}} \right\rceil - 1 \right) \times S - IK - JK$$

# Exemple: multiplication de matrice (2)

• Considérons une (2S)-partition:

$$Q \ge \left( \left\lceil \frac{|V|}{|P|} \right\rceil - 1 \right) \times S - |I|$$

• On a trouvé que  $|P| \le (2S)^{3/2}$  et |V| = 2IJK.

$$Q \ge \left( \left\lceil \frac{2IJK}{(2S)^{3/2}} \right\rceil - 1 \right) \times S - IK - JK$$

Borne asymptotique:

$$Q \geq \frac{IJK}{\sqrt{2S}}$$

# Exemple: multiplication de matrice (2)

• Considérons une (2S)-partition:

$$Q \ge \left( \left\lceil \frac{|V|}{|P|} \right\rceil - 1 \right) \times S - |I|$$

• On a trouvé que  $|P| \le (2S)^{3/2}$  et |V| = 2IJK.

$$Q \ge \left( \left\lceil \frac{2IJK}{(2S)^{3/2}} \right\rceil - 1 \right) \times S - IK - JK$$

Borne asymptotique:

$$Q \ge \frac{IJK}{\sqrt{2S}}$$

• **Raffinement:** Peut améliorer borne sur |P| (facteur  $2^{3/2}$ ):

$$Q \ge \frac{2IJK}{\sqrt{S}}$$

### ... ce dont je n'ai pas parlé.

- Raffinement de la borne sup sur la taille d'un K-ensemble
  - Projection dans des zones de l'InSet disjointes

## ... ce dont je n'ai pas parlé.

- Raffinement de la borne sup sur la taille d'un K-ensemble
  - Projection dans des zones de l'InSet disjointes
  - "Petites dimensions" (ex: convolution)

## .. ce dont je n'ai pas parlé.

- Raffinement de la borne sup sur la taille d'un K-ensemble
  - Projection dans des zones de l'InSet disjointes
  - "Petites dimensions" (ex: convolution)
- Théorème de Brascamp-Lieb: généralisation de Loomis-Whitney pour tout homomorphisme de groupe  $\phi_i$ 
  - ⇒ Permet des projections selon des directions arbitraires
  - ⇒ Analyse les dépendances du programme pour les trouver.

### .. ce dont je n'ai pas parlé.

- Raffinement de la borne sup sur la taille d'un K-ensemble
  - Projection dans des zones de l'InSet disjointes
  - "Petites dimensions" (ex: convolution)
- Théorème de Brascamp-Lieb: généralisation de Loomis-Whitney pour tout homomorphisme de groupe  $\phi_i$ 
  - ⇒ Permet des projections selon des directions arbitraires
  - ⇒ Analyse les dépendances du programme pour les trouver.
- Programme avec des nids de boucles non parfaitement imbriquées
  - ⇒ Combinaison de bornes venant de plusieurs sections du graphe

# Plan de l'exposé (toujours en cours)

- Introduction
  - Motivation générale
  - Complexité I/O
- 2 Red-white pebble game
- Borne inférieure
- 4 Borne supérieure
- 6 Résultats

# Borne supérieure d'une complexité I/O


- Borne inférieure: à quel point proche de la vraie valeur?
  - $\Rightarrow$  Veut un encadrement serré de la complexité I/O.

# Borne supérieure d'une complexité I/O


- Borne inférieure: à quel point proche de la vraie valeur?
  - ⇒ Veut un encadrement serré de la complexité I/O.

- Borne supérieure: essaye de trouver une partie (un ordonnancement) qui minimise le nombre de transfert.
  - ⇒ Indication sur comment optimiser un programme pour minimiser l'I/O.

# Background - tuilage de programme



## Background - tuilage de programme



- Tuilage: groupe des itérations en tuiles atomiques
- Localité des données, introduit niveau de granularité

## Background - autres notions

#### Emprunte mémoire (Footprint)

Ensemble des cases mémoires accédées par une portion de programme.

## Background - autres notions

#### Emprunte mémoire (Footprint)

Ensemble des cases mémoires accédées par une portion de programme.

#### Réutilisation mémoire

Utilisation multiple d'une donnée qui reste dans la mémoire rapide

Accès de tableau: dimension de réutilisation (ex:  $A[i,k] \sim j$ )

## Background - autres notions

#### Emprunte mémoire (Footprint)

Ensemble des cases mémoires accédées par une portion de programme.

#### Réutilisation mémoire

Utilisation multiple d'une donnée qui reste dans la mémoire rapide

Accès de tableau: dimension de réutilisation (ex:  $A[i,k] \sim j$ )

Peut calculer ces informations avec le modèle polyédrique.

## Espace des implémentations

- Classe de programme encore plus simple (tensor-like):
  - Boucles parfaitement imbriquées
  - Boucles pouvant être permutées
  - ⇒ Tuilable avec des tuiles rectangulaires

## Espace des implémentations

- Classe de programme encore plus simple (tensor-like):
  - Boucles parfaitement imbriquées
  - Boucles pouvant être permutées
  - ⇒ Tuilable avec des tuiles rectangulaires
- Forme des implémentations recherchées:
  - Programme tuilé
  - Tailles des tuiles sont des paramètres

#### Example

```
for (i1=0; i1<I; i1+=Ti)
    for (j1=0; j1<J; j1+=Tj)
    for (i=i1; i<min(i1+Ti,I); i++)
        for (j=j1; i<min(j1+Tj,J); j++)
        S(i,j);</pre>
```

# Espace des implémentations

- Classe de programme encore plus simple (tensor-like):
  - Boucles parfaitement imbriquées
  - Boucles pouvant être permutées
  - ⇒ Tuilable avec des tuiles rectangulaires
- Forme des implémentations recherchées:
  - Programme tuilé
  - Tailles des tuiles sont des paramètres

#### Example

```
for (i1=0; i1<I; i1+=Ti)
for (j1=0; j1<J; j1+=Tj)
for (i=i1; i<min(i1+Ti,I); i++)
for (j=j1; i<min(j1+Tj,J); j++)
S(i,j);
```

⇒ Quelle permutation de boucle? Tailles de tuile?



## Choix de la permutation de boucle


- **Contrainte:** emprunte mémoire de la tuile interne rentre dans la mémoire rapide.
  - ⇒ Permutation des boucles internes n'importe pas.

## Choix de la permutation de boucle

- **Contrainte:** emprunte mémoire de la tuile interne rentre dans la mémoire rapide.
  - ⇒ Permutation des boucles internes n'importe pas.
- Permutation de boucle au dessus? (beaucoup de choix)
  - Maximiser la réutilisation des données
  - Certaines dimensions sont meilleures que d'autres

## Choix de la permutation de boucle

- Contrainte: emprunte mémoire de la tuile interne rentre dans la mémoire rapide.
  - ⇒ Permutation des boucles internes n'importe pas.
- Permutation de boucle au dessus? (beaucoup de choix)
  - Maximiser la réutilisation des données
  - Certaines dimensions sont meilleures que d'autres
- Algorithme de sélection de permutation: (sur un exemple)



### Choix des taille de tuile - Fonction de coût

Pour une permutation donnée, minimiser l'I/O:

### Example (Matmult, permutation (i, j, k))

```
for (i1=0; i1<N_i; i1+=Ti)

for (j1=0; j1<N_j; j1+=Tj)

for (k=0; k<N_k; k++)

for (i=i1; i<min(i1+Ti,I); i++)

for (j=j1; i<min(j1+Tj,J); j++)

C[i,j] += A[i,k] × B[k,j];
```

• Suppose que  $T_i T_j + T_i + T_j < S$ 

### Choix des taille de tuile - Fonction de coût

Pour une permutation donnée, minimiser l'I/O:

### Example (Matmult, permutation (i, j, k))

```
for (i1=0; i1<N_i; i1+=Ti)

for (j1=0; j1<N_j; j1+=Tj)

for (k=0; k<N_k; k++)

for (i=i1; i<min(i1+Ti,I); i++)

for (j=j1; i<min(j1+Tj,J); j++)

C[i,j] += A[i,k] × B[k,j];
```

- Suppose que  $T_i T_j + T_i + T_j < S$
- Boucle sur k:
  - (k=0) Tout miss:  $T_i T_j + T_i + T_j$
  - (k>0) Réutilisation de C[i,j]:  $T_i + T_j$

$$\Rightarrow (T_i T_j + T_i + T_j) + (N_k - 1)(T_i + T_j) = (T_i T_j + N_k T_i + N_k T_j)$$

### Choix des taille de tuile - Fonction de coût

• Pour une permutation donnée, minimiser l'I/O:

### Example (Matmult, permutation (i, j, k))


- Suppose que  $T_i T_j + T_i + T_j < S$
- Boucle sur k:
  - (k=0) Tout miss:  $T_i T_j + T_i + T_j$
  - (k>0) Réutilisation de C[i,j]:  $T_i + T_j$

$$\Rightarrow (T_i T_j + T_i + T_j) + (N_k - 1)(T_i + T_j) = (T_i T_j + N_k T_i + N_k T_j)$$

• Avec les boucles sur i1 et j1 (tout le programme):

$$\frac{N_i}{T_i}\frac{N_j}{T_i}(T_iT_j+N_kT_i+N_kT_j)=N_iN_jN_k\left(\frac{1}{T_i}+\frac{1}{T_j}+\frac{1}{N_k}\right)$$

# Flot complet de IOUB - Multiplication de matrice



#### Automatisation

Borne inférieure: IOLB
 Sur tout programme polyédrique

 Borne supérieure: IOUB
 Sur une sous-classe de programme "tensor-like" (limitation du solver)

 Deux protos disponible en ligne: https://iocomplexity.corse.inria.fr/ Modélisation Borne inf Borne sup 00000 00000000 00000000

# Résultats IOLB sur Polybench (UB: calcul manuel)

Introduction

kernel	# input data	# ops	$Q_{low}^{\infty}$	$OI_{\text{manual}} \leq OI \leq OI_{\text{up}}$	ratio
2mm	$N_i N_k + N_k N_j$	2(NiN <sub>j</sub> N <sub>k</sub>	$2(N_iN_jN_k$	$\sqrt{S} \le OI \le \sqrt{S}$	1
	$+N_jN_l+N_lN_l$	$+N_iN_jN_l$	$+N_iN_jN_l)/\sqrt{S}$		
3mm	$N_i N_k + N_k N_j$	$2(NiN_jN_k + N_jN_lN_m$	$2(N_iN_jN_k + N_iN_jN_l)$	$\sqrt{S} \le OI \le \sqrt{S}$	1
	$+N_jN_m+N_mN_l$	$+N_iN_jN_l$	$+N_{i}N_{l}N_{m})/\sqrt{S}$		
cholesky	1/2 N <sup>2</sup>	$\frac{1}{3}N^{3}$	$\frac{1}{6}N^{3}/\sqrt{S}$	$\sqrt{S} \le OI \le 2\sqrt{S}$	2
correlation	MN	$M^2N$	$\frac{1}{2}M^2N/\sqrt{S}$	$\sqrt{S} \le OI \le 2\sqrt{S}$	2
covariance	MN	$M^2N$	$\frac{1}{2}M^2N/\sqrt{S}$	$\sqrt{S} \le OI \le 2\sqrt{S}$	2
doitgen	$N_p N_q N_r + N_p^2$	$2N_p^2N_qN_r$	$2N_p^2N_qN_r/\sqrt{S}$	$\sqrt{S} \le OI \le \sqrt{S}$	1
fdtd-2d	$3N_xN_y + T$	$11 N_{\times} N_{y} T$	$\frac{2}{3\sqrt{3}}N_XN_yT/\sqrt{S}$	$\frac{11}{24}\sqrt{3}\sqrt{S} \le OI \le \frac{33}{2}\sqrt{3}\sqrt{S}$	36
flovd-warshall	N <sup>2</sup>	2N <sup>3</sup>	$2N^3/\sqrt{S}$	$\sqrt{s}$ < 01 < $\sqrt{s}$	1
gemm	$N_iN_i + N_iN_k + N_iN_k$	$2N_iN_iN_k$	$2N_iN_iN_k/\sqrt{S}$	$\sqrt{s} < OI < \sqrt{s}$	1
heat-3d	N <sup>3</sup>	30 N <sup>3</sup> T	§ <sup>3</sup> √2N³ T / <sup>3</sup> √S	$\frac{5}{2}\sqrt[3]{5} < OI < 40 \cdot 2^{2/3}\sqrt[3]{5}$	16 · 2 <sup>2/3</sup>
jacobi-1d	l N	6NT	NT/S	<sup>2</sup> <sup>3</sup> / <sub>3</sub> S ≤ OI ≤ 24 S	16
jacobi-2d	N <sup>2</sup>	10 N <sup>2</sup> T	$\frac{2}{3\sqrt{3}}N^2T/\sqrt{S}$	$\frac{5}{4}\sqrt{S} \le OI \le 15\sqrt{3}\sqrt{S}$	12√3
lu	N <sup>2</sup>	<sup>2</sup> / <sub>3</sub> N <sup>3</sup>	$\frac{3\sqrt{3}}{3}N^{3}/\sqrt{S}$	$\sqrt{s}$ < $OI$ < $\sqrt{s}$	1
ludcmp	N <sup>2</sup>	$\frac{2}{3}N^{3}$	$\frac{2}{3}N^3/\sqrt{S}$	$\sqrt{S} \le OI \le \sqrt{S}$	1
seidel-2d	N <sup>2</sup>	9 N <sup>2</sup> T	$\frac{2}{3\sqrt{3}}N^2T/\sqrt{S}$	$\frac{9}{4}\sqrt{S} \le OI \le \frac{27\sqrt{3}}{2}\sqrt{S}$	6√3
symm	$\frac{1}{2}M^2 + 2MN$	$2M^2N$	$2M^2N/\sqrt{S}$	$\sqrt{S} \le OI \le \sqrt{S}$	1
syr2k	$\frac{1}{2}N^2 + 2MN$	$2MN^2$	$MN^2/\sqrt{S}$	$\sqrt{S} \le OI \le 2\sqrt{S}$	2
syrk	$\frac{1}{2}N^2 + MN$	$MN^2$	$\frac{1}{2}MN^2/\sqrt{S}$	$\sqrt{S} \le OI \le 2\sqrt{S}$	2
trmm	$\frac{1}{2}M^2 + MN$	$M^2N$	$M^2N/\sqrt{S}$	$\sqrt{S} \le OI \le \sqrt{S}$	1
atax	MN	4MN	MN	4≤ <i>OI</i> ≤4	1
bicg	MN	4MN	MN	4≤ <i>OI</i> ≤4	1
deriche	HW	32 <i>HW</i>	HW	$\frac{16}{3} \le OI \le 32$	6
gemver	N <sup>2</sup>	10N <sup>2</sup>	N <sup>2</sup>	5≤ <i>OI</i> ≤10	2
gesummv	2N <sup>2</sup>	4N <sup>2</sup>	2N <sup>2</sup>	2≤ OI ≤2	1
mvt	N <sup>2</sup>	4N <sup>2</sup>	N <sup>2</sup>	4≤ <i>OI</i> ≤4	1
trisolv	$\frac{1}{2}N^{2}$	N <sup>2</sup>	$\frac{1}{2}N^{2}$	2≤ <i>OI</i> ≤2	1
adi	N <sup>2</sup>	30 N <sup>2</sup> T	N <sup>2</sup> T	5≤ <i>OI</i> ≤30	6
durbin	N	$2N^2$	$\frac{1}{2}N^{2}$	$\frac{2}{3} \le OI \le 4$	6
gramschmidt	MN	2MN <sup>2</sup>	$MN^2/\sqrt{S}$	$1 \le OI \le 2\sqrt{5}$	2√5
nussinov	$\frac{1}{2}N^{2}$	$\frac{1}{3}N^{3}$	$\frac{1}{6}N^3/\sqrt{S}$	$1 \le OI \le 2\sqrt{S}$	2√5



Résultats


00000

### Résultats IOUB

	1 ,			
TC ab-ac-cb	$UB = \frac{2ABC}{\sqrt{S+1}-1} + BC$			
	LB = max $\left( AB + AC + CB, -2 + C - S + 2A + 2B + \frac{2AB(C-1)}{\sqrt{S}} \right)$			
TC abcd-aebf-fdec	$UB = \frac{2ABCDEF}{\sqrt{S+1}-1} + CDEF$			
	$LB = \max \left( ABCD + AEBF + FDEC, -3 + EF - S + 3AB + 3CD - ABCD + \frac{2ABCD(EF-1)}{\sqrt{S}} \right)$			
2D Convolution	UB = $CFHWXY\left(\frac{1}{XY} + \frac{1}{H\Delta W} + \frac{(H+\Delta-1)(W+X-1)}{H\Delta^2WX}\right)$ where $\Delta = \frac{-HW+W+\sqrt{W^2+4HSW-2HW^2+4SW+4S+W^2}}{2(HW+W+1)}$			
	$LB = \max \left(BC(Y + H - 1)(X + W - 1) + BFXY + FCHW,\right)$			
	$-2 - S + C + 4F + BY + BX + 2BXY - 2BXYF + \frac{BFXY(WHC-1)}{S}$			
	$-2 - S + C + 4F + BY + BX + 2BXY - 2BXFY + \frac{2BXYCF\sqrt{HW}}{\sqrt{S}} - \frac{2BXYF}{\sqrt{HWS}}$			
	$-2 - S + C + 4F + BY + BX + 2BXY - 2BXFY + \frac{2XYCF\sqrt{BHW}}{\sqrt{S}} - \frac{2XYF\sqrt{B}}{\sqrt{HWS}}$			

### Résultats IOUB

	10 /		
TC ab-ac-cb	$UB = \frac{2ABC}{\sqrt{S+1}-1} + BC$		
	LB = max $\left( AB + AC + CB, -2 + C - S + 2A + 2B + \frac{2AB(C-1)}{\sqrt{S}} \right)$		
TC abcd-aebf-fdec	$UB = \frac{2ABCDEF}{\sqrt{5+1}-1} + CDEF$		
	$LB = \max \left( ABCD + AEBF + FDEC, -3 + EF - S + 3AB + 3CD - ABCD + \frac{2ABCD(EF-1)}{\sqrt{S}} \right)$		
2D Convolution	UB = $CFHWXY\left(\frac{1}{XY} + \frac{1}{H\Delta W} + \frac{(H+\Delta-1)(W+X-1)}{H\Delta^2WX}\right)$ where $\Delta = \frac{-HW+W+\sqrt{H^2W^2+4HSW-2HW^2+4SW+4S+W^2}}{2(HW+W+1)}$		
	$LB = \max \left(BC(Y + H - 1)(X + W - 1) + BFXY + FCHW,\right)$		
	$-2 - S + C + 4F + BY + BX + 2BXY - 2BXYF + \frac{BFXY(WHC-1)}{S}$		
	$-2 - S + C + 4F + BY + BX + 2BXY - 2BXFY + \frac{2BXYCF\sqrt{HW}}{\sqrt{S}} - \frac{2BXYF}{\sqrt{HWS}},$		
	$-2-S+C+4F+BY+BX+2BXY-2BXFY+\frac{2XYCF\sqrt{BHW}}{\sqrt{S}}-\frac{2XYF\sqrt{B}}{\sqrt{HWS}}\right)$		







# Directions en cours/futures (aka TODO-list)

- Amélioration de borne inférieure:
  - Calculs de stencils: facteur multiplicatif
  - gramschmidt + nussinov : ratio à améliorer

- Utilisation de l'ordonnancement trouvé par IOUB
  - Possible d'appliquer l'algo sur plusieurs niveaux mémoire
  - Modèle idéal (scratchpad) ≠ Vrai cache
  - Utilisable en première approximation?

### Merci de votre attention...

... Avez-vous des questions?